

Comparación de Modelos de Machine Learning para Predicción de Abandono de Clientes

Análisis utilizando KNN, Random Forest y SVM

Nombre: Vanessa del carmen Reichenberger Marte

Fecha: 27/02/2026

Herramientas: Python, Scikit-learn, Pandas, Matplotlib

Comparación de Modelos de Machine Learning para la Predicción de Enfermedades Cardíacas

Introducción:

El presente proyecto tiene como objetivo aplicar y comparar distintos algoritmos de Machine Learning para predecir la presencia de enfermedad cardíaca en pacientes, utilizando un dataset de libre acceso.

Se busca evaluar el rendimiento de tres modelos de clasificación y determinar cuál ofrece mejores resultados en términos de precisión y capacidad predictiva.

Dataset:

Se utilizó el dataset **Heart Disease**, disponible en plataformas de acceso abierto como Kaggle.

Este conjunto de datos contiene información clínica de pacientes, incluyendo variables como edad, presión arterial, colesterol, frecuencia cardíaca, entre otras.

La variable objetivo corresponde a la presencia o ausencia de enfermedad cardíaca.

Preprocesamiento de los Datos:

Antes de entrenar los modelos, se realizó un proceso de limpieza y preparación de los datos:

- Eliminación de posibles espacios en los nombres de columnas
- Verificación de valores nulos (no se encontraron datos faltantes)
- Separación de variables independientes (X) y variable objetivo (y)
- Escalado de los datos mediante **StandardScaler**, especialmente importante para modelos sensibles a la escala como KNN y SVM
- División del dataset en conjunto de entrenamiento (80%) y prueba (20%)

Este proceso asegura la calidad de los datos y evita sesgos en el entrenamiento.

Modelos Aplicados:

Se entrenaron tres algoritmos de clasificación:

- K-Nearest Neighbors (KNN)

Modelo basado en la proximidad entre datos. Clasifica en función de los vecinos más cercanos.

- Random Forest

Modelo basado en múltiples árboles de decisión. Es robusto y reduce el sobreajuste.

-Support Vector Machine (SVM)

Modelo que busca el mejor hiperplano para separar las clases. Es eficaz en espacios de alta dimensión.

Evaluación de Modelos:

Los modelos fueron evaluados utilizando las siguientes métricas:

- Accuracy (Exactitud)
- Precision
- Recall
- F1-score

Además, se utilizaron:

- Curvas ROC (Receiver Operating Characteristic)
- Matrices de confusión
- Visualizaciones comparativas

Estas métricas permiten una evaluación integral del rendimiento de cada modelo.

Resultados:

Los resultados obtenidos muestran diferencias claras en el desempeño de los modelos:

- **Random Forest** presentó el mejor rendimiento general, con alta precisión y equilibrio entre recall y F1-score
- **SVM** mostró un desempeño competitivo, aunque ligeramente inferior en algunos casos
- **KNN** fue el modelo con menor rendimiento relativo, siendo más sensible a la escala de los datos

Las visualizaciones (gráficas de métricas y curvas ROC) permitieron comparar de forma clara el comportamiento de cada algoritmo.

Análisis

El modelo Random Forest destacó debido a su capacidad de manejar relaciones complejas entre variables y su resistencia al sobreajuste.

SVM demostró ser eficaz, pero requiere mayor ajuste de parámetros para optimizar su rendimiento.

KNN, aunque simple e intuitivo, depende fuertemente de la estructura de los datos y puede verse afectado por ruido o escalado inadecuado.

Conclusión

En base a los resultados obtenidos, se concluye que el modelo **Random Forest** es el más adecuado para este problema de clasificación, debido a su alto rendimiento y estabilidad.

Este proyecto demuestra la importancia de comparar múltiples modelos y utilizar diversas métricas de evaluación para tomar decisiones informadas en Machine Learning.